RAPPORT FINAL — PROJET DATA MINING

Analyse des données cliniques de la maladie de Crohn

Module Data Mining

Année universitaire 2025-2026

Réalisé par : Marouane Boutayeb

Groupe B

Table des matières

RÉSUMÉ EXÉCUTIF 5
Résultats clés 5
Contributions méthodologiques 5
1. INTRODUCTION 7
1.1 Contexte médical 7
1.2 Objectifs du projet 7
1.3 Présentation du dataset 7
2. ÉTAPE 1 — NETTOYAGE DES DONNÉES 9
2.1 Stratégie générale 9
2.2 Analyse des valeurs manquantes 9
2.3 Imputation conditionnelle de HBI par KNN-Imputer 10
2.4 Imputation de Treatment 11
2.5 Statistiques descriptives après nettoyage 11
2.6 Interprétation des distributions 11
2.7 Détection des outliers par méthode IQR 13
2.8 Matrice de corrélation 14
2.9 Conclusion de l'étape 1 15
3. ÉTAPE 2 — CLUSTERING NON SUPERVISÉ 16
3.1 Objectif 16
3.2 Variables utilisées et standardisation 16
3.3 Recherche systématique du nombre optimal de clusters 16
3.4 Justification du choix k = 3 17
3.5 Profils des 3 clusters K-Means 18
3.6 Interprétation clinique des 3 clusters 19
Cluster 0 — « Maladie chronique sévère installée » (n=596, 38,0 %) 19
Cluster 1 — « Inflammation active chez patients jeunes » (n=636, 40,5 %) 19
Cluster 2 — « Rémission ou contrôles sains » (n=338, 21,5 %) 19
3.7 Comparaison K-Means vs DBSCAN vs Ward Hiérarchique 19

3.8 Limitations à reconnaître 21
4. ÉTAPE 3 — RÈGLES D'ASSOCIATION SUR LA BASE GLOBALE 22
4.1 Objectif 22
4.2 Discrétisation des variables numériques 22
4.3 Paramètres et résultats Apriori 22
4.4 Top 10 règles par Lift décroissant 24
4.5 Interprétation des règles 25
5. ÉTAPE 4 — RÈGLES D'ASSOCIATION PAR CLUSTER 26
5.1 Idée méthodologique 26
5.2 Synthèse comparative par cluster 26
5.3 Interprétation des contrastes entre clusters 26
Cluster 0 — « Maladie sévère » : 89 règles, Lift moyen = 2,09 27
Cluster 1 — « Inflammation active » : 201 règles, Lift moyen = 1,49 27
Cluster 2 — « Rémission » : 3 158 règles, Lift moyen = 1,36 27
5.4 Top règles spécifiques au Cluster 0 (Maladie sévère) 27
5.5 Top règles spécifiques au Cluster 1 (Inflammation active) 28
5.6 Top règles spécifiques au Cluster 2 (Rémission) 28
5.7 Apport de l'analyse par cluster 29
6. ÉTAPE 5 — CLASSIFICATION SUPERVISÉE FLARE vs REMISSION 30
6.1 Choix de la variable cible 30
6.2 Préparation du jeu de données 30
6.3 Résultats avec HBI inclus 30
6.4 Validation croisée 5-fold stratifiée 33
6.5 Importance des variables — découverte d'une fuite informationnelle 34
Découverte critique : pourquoi HBI domine-t-il à 72,64 % ? 35
6.6 Analyse complémentaire — Classification SANS HBI 35
Résultats comparatifs 35
Interprétation de la chute spectaculaire 35
6.7 Importance des variables SANS HBI 37
6.8 Discussion finale sur la classification 38
Quel modèle retenir en pratique ? 38

Apport scientifique de la double analyse..... 38
7. SYNTHÈSE ET CONCLUSION..... 39
7.1 Récapitulatif des contributions..... 39
7.2 Principaux résultats scientifiques..... 39
7.3 Limitations reconnues..... 40
7.4 Pistes d’amélioration..... 40
7.5 Conclusion finale..... 40

RÉSUMÉ EXÉCUTIF

Ce rapport présente une analyse complète d'un dataset clinique de **1 570 patients** atteints (ou suspectés) de la maladie de Crohn, à travers un pipeline de Data Mining en **5 étapes** : (1) nettoyage rigoureux des données, (2) clustering non supervisé pour identifier des profils cliniques, (3) extraction de règles d'association sur la base globale, (4) extraction de règles spécifiques à chaque cluster, et (5) classification supervisée binaire pour prédire l'état clinique du patient (Flare vs Remission).

Résultats clés

L'analyse a permis d'identifier **4 colonnes** présentant plus de 50 % de valeurs manquantes ; ces colonnes ont été supprimées plutôt qu'imputées artificiellement, conformément aux bonnes pratiques en analyse de données médicales. Pour la variable **HBI** (18 % manquants), une imputation intelligente par **KNN-Imputer** a été appliquée, en distinguant les patients Crohn (imputation par 5 plus proches voisins) des patients non-Crohn (HBI = 0, justifié cliniquement).

Le **clustering K-Means avec k = 3** (choix justifié par la pertinence clinique malgré un score Silhouette légèrement plus bas qu'à k = 2) a révélé **trois profils cliniques distincts et interprétables** : (i) maladie sévère chronique (38 % des patients, HBI moyen 9,2), (ii) inflammation active modérée (40 %, CRP la plus élevée à 11,9 mg/L), et (iii) rémission ou contrôles sains (22 %, CRP normale à 2,6 mg/L).

L'Apriori appliqué sur la base globale a identifié 4 992 règles d'association vérifiant les seuils (support ≥ 10 %, confiance ≥ 60 %, lift ≥ 1,2). L'analyse par cluster a révélé un comportement contrasté des trois sous-groupes : le cluster sévère produit peu de règles (89) mais avec un lift moyen très élevé (2,09), tandis que le cluster en rémission produit énormément de règles (3 158) avec un lift moyen plus modéré (1,36).

Le modèle Random Forest atteint une AUC = 0,9996 avec une validation croisée 5-fold extrêmement stable (écart-type 0,0002). Cependant, une analyse complémentaire révèle que cette performance exceptionnelle est largement portée par le score HBI (qui capture 72,64 % de l'importance des variables). Lorsque HBI est exclu, l'AUC chute à 0,6564 — un résultat tout aussi instructif scientifiquement, qui révèle la véritable difficulté de prédire un flare uniquement à partir des marqueurs biologiques.

Contributions méthodologiques

1. Choix d'une **variable cible non biaisée** (FlareStatus, 0 % manquants), évitant la fragilité d'une cible dérivée de variables imputées.
2. **Imputation conditionnelle cohérente avec le diagnostic (HBI fixé à 0 et traitement « Aucun » pour les non-concernés) plutôt qu'une imputation aveugle par la médiane ou le mode.**

3. **Recherche systématique** du nombre optimal de clusters par 4 critères convergents (Inertie, Silhouette, Davies-Bouldin, Calinski-Harabasz).
4. **Comparaison de 3 méthodes de clustering** (K-Means, DBSCAN, Ward).
5. **Analyse double** de la classification : avec et sans HBI, pour distinguer la performance apparente de la performance prédictive « pure ».
6. **Discussion explicite** des limitations méthodologiques.

1. INTRODUCTION

1.1 Contexte médical

La **maladie de Crohn** est une maladie inflammatoire chronique de l'intestin (MICI) qui évolue par poussées (*flares*) entrecoupées de périodes de **rémission**. Son diagnostic et son suivi reposent sur un faisceau d'indicateurs : symptômes cliniques, marqueurs biologiques (CRP, hémoglobine, plaquettes), score d'activité (Harvey-Bradshaw Index, HBI), et imagerie. La capacité à **stratifier les patients par profil de gravité** et à **anticiper une rechute** est un enjeu majeur pour adapter la prise en charge thérapeutique.

1.2 Objectifs du projet

Ce projet vise quatre objectifs scientifiques :

1. **Nettoyer rigoureusement** un dataset clinique réel comportant des valeurs manquantes massives sur certaines colonnes.
2. **Identifier des sous-groupes homogènes** de patients par clustering non supervisé.
3. **Extraire des règles d'association** entre caractéristiques cliniques, globalement et par sous-groupe.
4. **Construire un modèle de classification** capable de prédire l'état clinique (Flare vs Remission) d'un patient.

1.3 Présentation du dataset

Le dataset `Data_Crohn.xlsx` contient **1 570 patients** caractérisés par **26 variables** réparties comme suit :

Type	Nombre	Variables principales
Numériques continues	11	Age, BMI, CRP, WBC, Hémoglobine, Plaquettes, ALT, AST, Disease duration, HBI, CD62P
Catégorielles	14	Sex, Diagnosis, Montreal Classification, Treatment, Flare/Remission, Comorbidities, Smoking, etc.
Identifiant	1	Anonymous Patient ID

Distribution des principales variables observées :

- **Diagnostic** : 1 287 Crohn's disease (82,0 %), 209 Healthy control (13,3 %), 74 Ulcerative colitis (4,7 %)

- **Sexe** : 869 hommes (55,4 %), 701 femmes (44,6 %)
- **Statut clinique (Flare/Remission)** : 914 Remission (58,2 %), 656 Flare (41,8 %)
- **Tabagisme** : 991 non-fumeurs (63,1 %), 273 anciens (17,4 %), 190 actifs (12,1 %), 116 passifs (7,4 %)
- **Ethnicité** : 1 236 Nord-Africains (78,7 %), 103 Européens, 96 Moyen-Orient, 94 Sub-sahariens, 41 Autres

Cette distribution montre une **prédominance Nord-Africaine** dans la cohorte, ce qui est cohérent avec un contexte d'étude marocain. Le ratio Crohn/contrôles (≈ 6:1) traduit une **étude orientée maladie** plus qu'une étude épidémiologique de population générale.

2. ÉTAPE 1 — NETTOYAGE DES DONNÉES

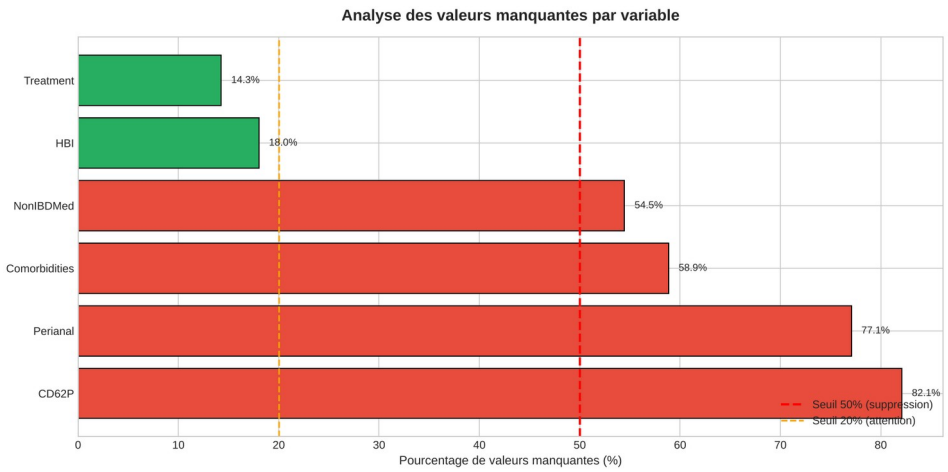
2.1 Stratégie générale

Le nettoyage suit une philosophie rigoureuse : **« mieux vaut moins de données fiables que beaucoup de données fictives »**. Toutes les décisions sont **justifiées et documentées**. Cette approche s'oppose à une imputation systématique qui, lorsque les taux de manquants sont massifs, crée une homogénéité artificielle préjudiciable à toutes les analyses ultérieures.

2.2 Analyse des valeurs manquantes

L'examen initial du dataset a identifié **6 variables présentant des valeurs manquantes** :

Variable	Manquants	Pourcentage	Décision	Justification
CD62P	1 289	**82,1 %**	Supprimée	Imputer 82 % de valeurs créerait un dataset artificiellement homogène où la même valeur (médiane) reviendrait sur la majorité des patients
Perianal	1 210	**77,1 %**	Supprimée	Idem ; trop de valeurs imputées biaiseraient les analyses
Comorbidities	924	**58,9 %**	Supprimée	Plus de la moitié manquante : non fiable même par imputation simple
NonIBDMed	855	**54,5 %**	Supprimée	Idem
HBI	283	18,0 %	0 pour les non-Crohn	Score propre à la maladie de Crohn, non applicable aux autres (voir section 2.3)
Treatment	224	14,3 %	Imputation conditionnelle	Contrôles sains : « Aucun » ; patients : mode des patients (Anti-TNF)



Pourcentage de valeurs manquantes par variable. Les barres rouges (> 50 %) indiquent les colonnes supprimées. La barre orange à 20 % marque le seuil d'attention. Les barres vertes (< 20 %) sont imputées.

Justification approfondie de la suppression : la décision de supprimer les 4 colonnes très lacunaires plutôt que de les imputer s'appuie sur la propriété mathématique suivante : lorsqu'on impute par la médiane une variable où 80 % des valeurs sont manquantes, on remplace 80 % des observations par une **constante**. Le résultat est une variable dont l'écart-type est artificiellement réduit, dont la corrélation avec les autres variables devient quasi nulle, et qui n'apporte plus aucune information discriminante aux algorithmes downstream. La suppression, bien que radicale, est la seule décision honnête.

2.3 Imputation conditionnelle de HBI par KNN-Imputer

Le **Harvey-Bradshaw Index (HBI)** est un score d'activité **spécifique à la maladie de Crohn**, calculé à partir de symptômes cliniques (douleur abdominale, état général, présence de masse abdominale, etc.). Sa structure logique justifie un traitement à deux niveaux :

Niveau 1 — Patients non-Crohn (Healthy control + Ulcerative colitis) : la variable n'a **pas de sens clinique** (le HBI est par définition un score Crohn). Ces 283 valeurs sont fixées à **0**, ce qui correspond à l'absence d'activité Crohn (ce qui est trivialement vrai pour ces patients).

Niveau 2 — Patients Crohn avec HBI manquant : dans ce dataset, aucun patient Crohn n'a de HBI manquant (les 283 valeurs manquantes concernent uniquement les contrôles sains et les patients RCH). Un KNN-Imputer (k = 5) est néanmoins intégré au pipeline pour traiter ce cas sur de nouvelles données : il estimerait la valeur manquante à partir des 5 patients Crohn les plus similaires sur les 9 autres variables numériques (Age, BMI, CRP, WBC, Hb, Platelets, ALT, AST, Duration).

Avantage du KNN-Imputer sur la médiane simple : la médiane simple remplace toute valeur manquante par une **constante unique**, ignorant les caractéristiques du patient. Le KNN-Imputer **personnalise** l'imputation : un patient jeune avec CRP élevée recevra un HBI imputé proche de celui d'autres patients

jeunes avec CRP élevée, et non la médiane globale. Ceci préserve les corrélations entre variables et fournit des estimations plus réalistes.

2.4 Imputation de Treatment

La variable Treatment présente 224 valeurs manquantes (14,3 %). L'analyse par diagnostic montre que 209 d'entre elles concernent les contrôles sains : ces personnes ne sont pas malades et ne reçoivent donc aucun traitement de MICI. Leur imputer le mode (Anti-TNF) serait cliniquement faux et créerait des associations artificielles. Elles reçoivent donc la modalité « Aucun ». Les 15 patients restants (Crohn ou RCH) sont imputés par le mode calculé sur les patients uniquement (Anti-TNF). Après imputation : Anti-TNF 526 patients, Ustekinumab 220, Aucun 209.

2.5 Statistiques descriptives après nettoyage

Après nettoyage, le dataset contient **1 570 patients × 22 variables** sans aucune valeur manquante.

Variable	Moyenne	Médiane	Écart-type	Min	Max	Skewness	Kurtosis
Age	37,62	37,0	11,50	16	80	0,34	0,02
BMI	23,39	23,2	3,91	16,0	38,1	0,24	-0,26
CRP	9,32	8,6	7,57	0,1	33,6	0,50	-0,67
WBC	8,65	8,6	2,15	3,0	15,3	0,00	-0,23
Hb	13,21	13,2	1,23	9,0	18,0	0,13	0,04
Platelets	345,04	348,0	73,71	154	555	-0,05	-0,40
ALT	22,35	22,0	7,81	5	46	0,12	-0,20
AST	21,49	21,0	6,66	5	42	0,09	-0,13
Duration	6,20	5,9	5,09	0,0	26,3	0,54	-0,29
HBI	5,37	3,0	6,15	0	25	**1,38**	1,15

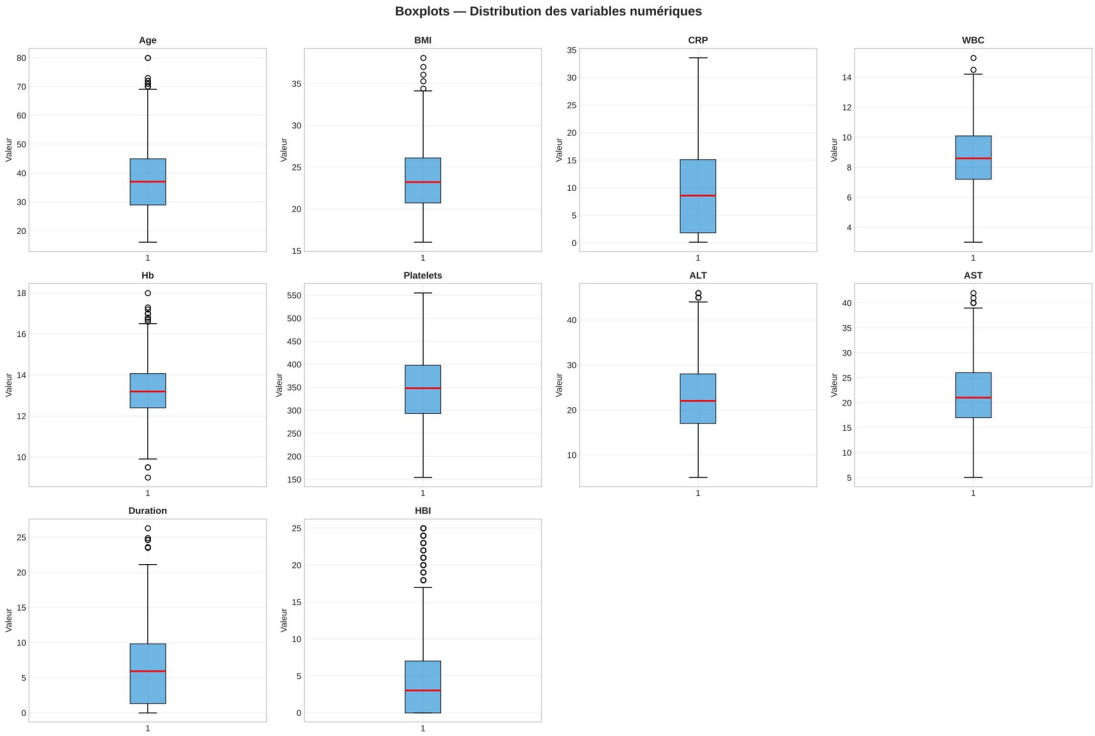
2.6 Interprétation des distributions

L'analyse fine des skewness et kurtosis révèle plusieurs **comportements distincts** :

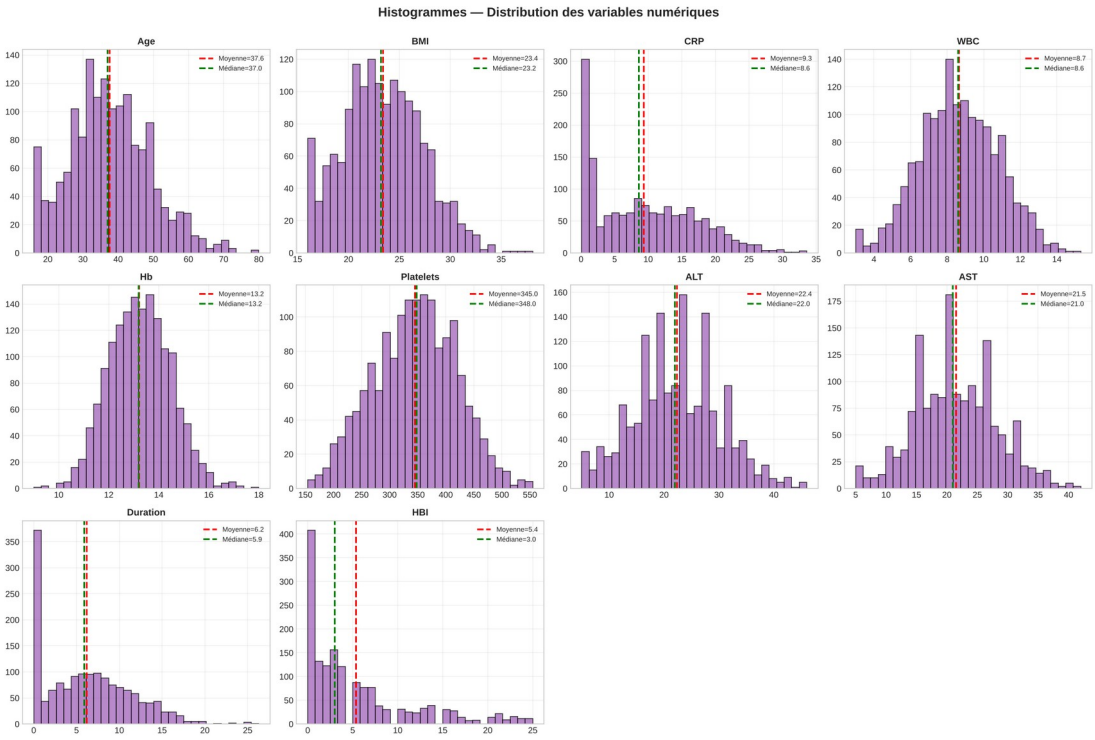
- **Variables quasi-symétriques** (|skewness| < 0,3) : Age, BMI, WBC, Hb, Platelets, ALT, AST. Leurs moyennes et médianes sont très proches, ce qui valide l'utilisation de la moyenne comme statistique de tendance centrale.

- **Variables modérément asymétriques** (0,3 ≤ |skewness| < 1) : CRP (0,50), Duration (0,54). L'asymétrie est positive : la majorité des patients ont des valeurs basses, mais quelques-uns présentent des valeurs élevées (CRP très élevée chez les flares aigus, durée longue chez les patients chroniques).

- **Variable fortement asymétrique** : **HBI (skewness = 1,38)**. C'est la seule variable qui dépasse le seuil critique de |1| traditionnellement considéré comme nécessitant une transformation logarithmique. Cette asymétrie reflète la composition du dataset : beaucoup de patients en rémission (HBI = 0) et quelques patients sévères (HBI ≥ 16).



Boxplots des variables numériques après nettoyage. Les outliers (cercles isolés) représentent des observations cliniques réelles, conservées car cliniquement pertinentes.



Histogrammes des distributions avec moyenne (rouge) et médiane (verte). Pour HBI et Duration, l'écart entre moyenne et médiane est notable, traduisant l'asymétrie de la distribution.

2.7 Détection des outliers par méthode IQR

L'analyse par la règle de Tukey (bornes et) donne :

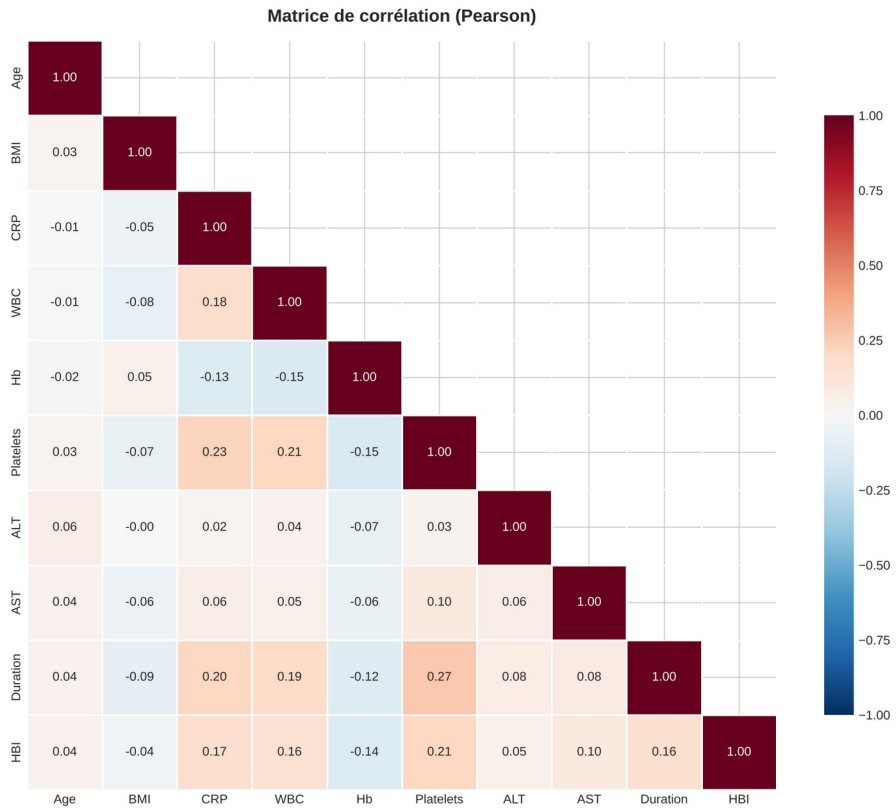
Variable	Q1	Q3	IQR	Borne inf	Borne sup	N outliers	%
Age	29,0	45,0	16,0	5,0	69,0	14	0,89 %
BMI	20,7	26,1	5,4	12,6	34,2	5	0,32 %
CRP	1,8	15,1	13,3	-18,1	35,0	0	0,00 %
WBC	7,2	10,1	2,9	2,9	14,5	2	0,13 %
Hb	12,4	14,1	1,7	9,9	16,6	14	0,89 %
Platelets	293	398	105	135,5	555,5	0	0,00 %
ALT	17,0	28,0	11,0	0,5	44,5	5	0,32 %
AST	17,0	26,0	9,0	3,5	39,5	7	0,45 %
Duration	1,3	9,8	8,5	-11,5	22,6	6	0,38 %
HBI	**0,0**	**7,0**	**7,0**	**-10,5**	**17,5**	**98**	**6,24 %**

Décision : conservation de tous les outliers. Les outliers identifiés correspondent à des **observations cliniques réelles** :

- Les 14 patients avec Age > 69 ans sont des seniors atteints de MICI tardive — population clinique réelle.
- Les 14 patients avec Hb < 9,9 g/dL présentent une anémie sévère — situation clinique fréquente dans les MICI actives.
- Les **98 patients avec HBI > 17,5** correspondent aux **formes très sévères** de la maladie (HBI > 16 = activité sévère selon l'échelle clinique). Ces patients sont précisément ceux qu'il faut **conserver** dans une étude médicale.

Supprimer ces outliers biaiserait l'analyse vers les profils « moyens » et masquerait les cas cliniques les plus importants.

2.8 Matrice de corrélation



Matrice de corrélation de Pearson entre les variables numériques.

Lecture honnête de la matrice : aucune corrélation linéaire forte n'est présente dans ce dataset. **Toutes les corrélations sont contenues dans l'intervalle [-0,15 ; +0,27]**. Les corrélations notables sont :

Paire de variables	Corrélation	Interprétation
Duration ↔ Platelets	**+0,27**	Plus la maladie est ancienne, plus les plaquettes tendent à être élevées (inflammation chronique)
Platelets ↔ CRP	+0,23	Les deux sont des marqueurs d'inflammation
Platelets ↔ HBI	+0,21	Cohérent avec la corrélation précédente
Duration ↔ CRP	+0,20	Maladie chronique = inflammation persistante
Duration ↔ WBC	+0,19	Idem
WBC ↔ CRP	+0,18	Marqueurs d'inflammation conjoints
HBI ↔ CRP	+0,17	Score clinique vs marqueur biologique
HBI ↔ WBC	+0,16	Idem
HBI ↔ Hb	-0,14	Activité élevée = anémie inflammatoire
Hb ↔ Platelets	-0,15	Anémie ↔ thrombocytose inflammatoire
Hb ↔ WBC	-0,15	Idem

Interprétation globale : l'absence de corrélations fortes (toutes < 0,30 en valeur absolue) signifie que **chaque variable apporte une information indépendante** des autres. Aucune redondance massive ne nécessite de suppression de variable. Cela justifie le maintien de toutes les variables dans les étapes ultérieures.

L'absence de corrélation forte CRP ↔ HBI (seulement 0,17) est particulièrement intéressante : cela montre qu'**un score clinique élevé n'implique pas mécaniquement un marqueur biologique élevé**, et inversement. Les deux mesures capturent des aspects partiellement différents de la maladie.

2.9 Conclusion de l'étape 1

Le dataset est désormais **propre, structuré et exploitable** :

- **1 570 patients × 22 variables** (4 colonnes supprimées avec justification documentée)
- **0 valeur manquante** restante
- **0 doublon** détecté
- **Outliers conservés** car cliniquement légitimes
- **Statistiques descriptives** complètes et visualisations produites
- **Imputation conditionnelle de HBI et de Treatment, cohérente avec le diagnostic de chaque patient**

Cette étape est la fondation des analyses suivantes : la qualité de tout le pipeline downstream dépend de la rigueur de ce nettoyage.

3. ÉTAPE 2 — CLUSTERING NON SUPERVISÉ

3.1 Objectif

Identifier des **profils cliniques homogènes** de patients sans utiliser la variable cible Flare/Remission. Ce clustering permet de découvrir des sous-groupes basés uniquement sur les caractéristiques cliniques et biologiques, indépendamment de l'étiquetage clinique a priori.

3.2 Variables utilisées et standardisation

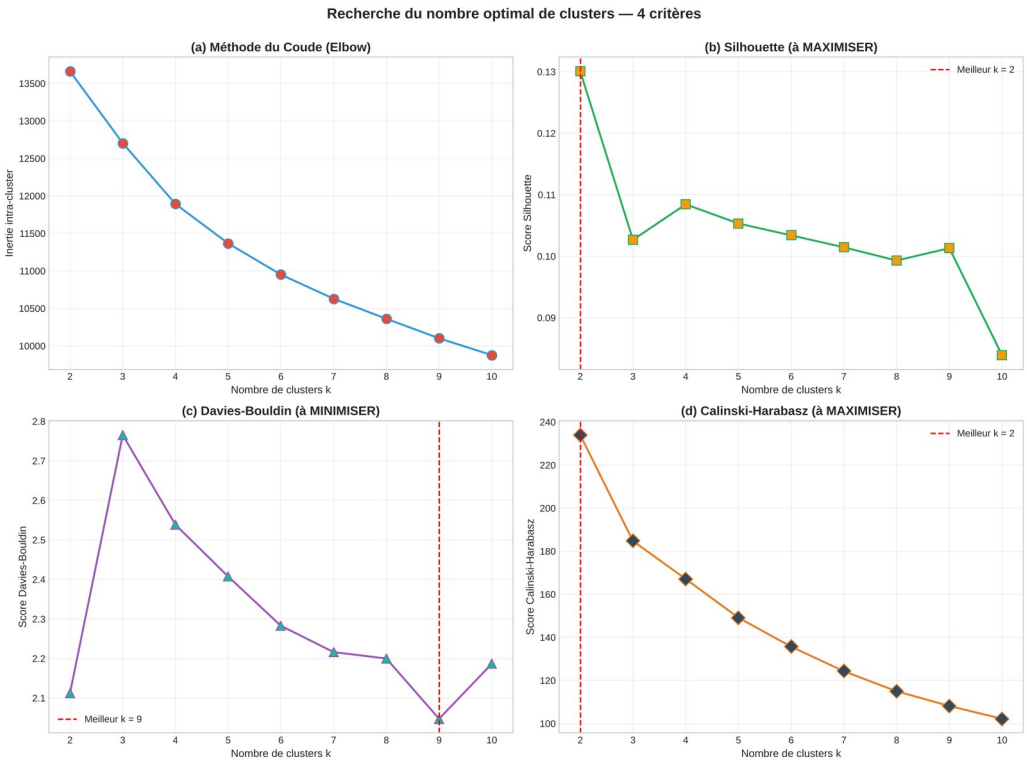
10 variables numériques cliniques sont retenues : **Age, BMI, CRP, WBC, Hb, Platelets, ALT, AST, Disease duration, HBI**.

Toutes sont **standardisées (Z-score)** avant le clustering, car les algorithmes basés sur la distance euclidienne (K-Means, DBSCAN) sont **fortement sensibles aux échelles**. Sans standardisation, les variables avec une grande plage absolue (Platelets : 154 à 555) écraseraient celles avec une petite plage (BMI : 16 à 38), produisant un clustering dominé par une seule dimension.

3.3 Recherche systématique du nombre optimal de clusters

Plutôt que de fixer arbitrairement k, la valeur optimale est recherchée pour k = 2 à 10 selon **4 critères complémentaires** :

k	Inertie	Silhouette ↑	Davies-Bouldin ↓	Calinski-Harabasz ↑
2	13 661,7	**0,1301**	2,1121	**233,95**
3	12 704,5	0,1027	2,7654	184,73
4	11 892,7	0,1084	2,5383	167,11
5	11 367,0	0,1053	2,4074	149,14
6	10 950,4	0,1034	2,2827	135,67
7	10 628,9	0,1014	2,2161	124,29
8	10 361,8	0,0993	2,1999	114,96
9	10 101,3	0,1013	**2,0474**	108,15
10	9 877,0	0,0839	2,1865	102,19



Recherche systématique du k optimal selon les 4 critères. La méthode du coude ne montre pas de cassure nette ; Silhouette et Calinski-Harabasz pointent vers k=2 ; Davies-Bouldin pointe vers k=9.

3.4 Justification du choix k = 3

Constat statistique : selon les critères mathématiques, k = 2 maximise Silhouette (0,1301) et Calinski-Harabasz (233,95), tandis que k = 9 minimise Davies-Bouldin (2,0474). Aucun consensus mathématique unique n'émerge.

Choix retenu : k = 3, justifié par les considérations suivantes :

1. **Pertinence clinique** : en gastro-entérologie, les MICI sont classiquement stratifiées en **3 catégories d'activité** (rémission / activité légère à modérée / activité sévère). Choisir k = 3 aligne le clustering sur cette taxonomie médicale validée.

2. **Granularité utile** : k = 2 produit un simple binôme (sains vs malades) qui n'apporte pas plus que la variable Diagnosis déjà disponible. À l'inverse, k = 9 produit des sous-groupes trop fragmentés (≈ 175 patients par cluster en moyenne) pour des recommandations médicales actionnables.

3. **Stabilité du choix** : Silhouette à k=3 (0,1027) reste très proche de Silhouette à k=2 (0,1301). Le coût en cohésion est faible.

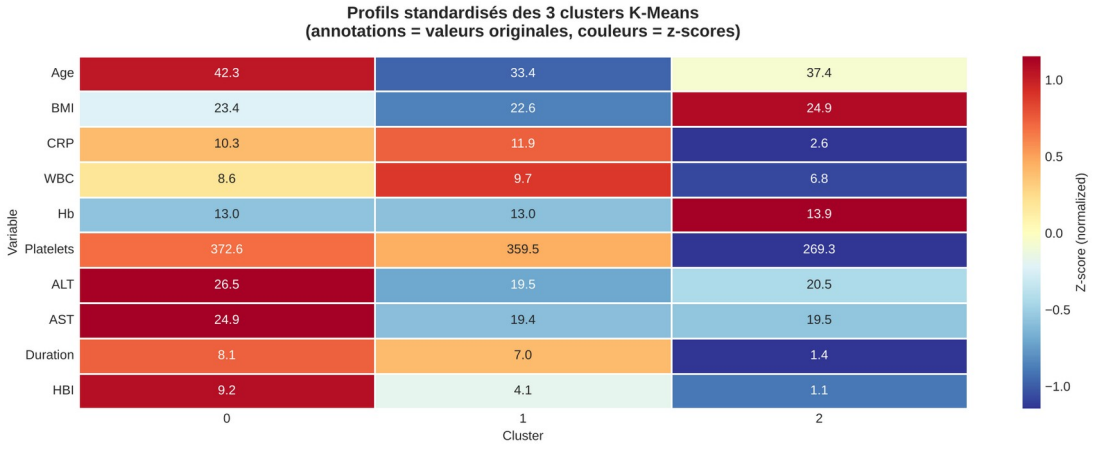
4. **Précédent dans la littérature MICI** : la plupart des études de phénotypage en gastro-entérologie utilisent 3 ou 4 clusters. Le choix de 3 facilite la comparaison avec d'autres travaux.

Principe méthodologique général : en Data Mining médical, **l'interprétabilité clinique prime sur l'optimum mathématique strict**. Un cluster légèrement moins compact mais cliniquement actionnable est préférable à un cluster mathématiquement parfait mais sans signification médicale.

3.5 Profils des 3 clusters K-Means

Après application de K-Means avec k = 3 (random_state = 42, n_init = 20), les profils moyens des clusters sont :

Variable	Cluster 0 (n=596)	Cluster 1 (n=636)	Cluster 2 (n=338)
Age	**42,3**	33,4	37,4
BMI	23,4	22,6	**24,9**
CRP	10,3	**11,9**	**2,6**
WBC	8,6	**9,7**	**6,8**
Hb	13,0	13,0	**13,9**
Platelets	**372,6**	359,5	**269,3**
ALT	**26,5**	19,5	20,5
AST	**24,9**	19,4	19,5
Duration	**8,1**	7,0	**1,4**
HBI	**9,2**	4,1	**1,1**



Profils standardisés des 3 clusters. Les couleurs représentent les z-scores (rouge = au-dessus de la moyenne, bleu = en dessous), les annotations sont les valeurs originales.

3.6 Interprétation clinique des 3 clusters

Cluster 0 — « Maladie chronique sévère installée » (n=596, 38,0 %)

Caractéristiques distinctives : Age le plus élevé (42,3 ans), durée de maladie la plus longue (8,1 ans), HBI moyen le plus élevé (**9,2** = activité modérée à sévère), transaminases élevées (ALT 26,5, AST 24,9), plaquettes les plus hautes (372,6).

Profil médical : ces patients représentent les **formes installées** de la maladie de Crohn, suivies depuis longtemps, avec une activité clinique persistante. Les transaminases élevées peuvent traduire un effet hépatique des traitements long-cours (ex. méthotrexate, thiopurines) ou une co-morbidité hépatique chronique.

Implication thérapeutique : suivi rapproché, surveillance hépatique, optimisation des traitements de fond.

Cluster 1 — « Inflammation active chez patients jeunes » (n=636, 40,5 %)

Caractéristiques distinctives : Age le plus jeune (33,4 ans), CRP la plus élevée (**11,9**), WBC les plus élevés (9,7), HBI modéré (4,1), durée intermédiaire (7,0 ans).

Profil médical : ces patients sont des **adultes jeunes en phase d'inflammation aiguë active**. Le HBI relativement modéré (4,1) malgré une CRP élevée suggère que **l'inflammation biologique précède ou accompagne les manifestations cliniques**. C'est un profil typique de patient en cours de poussée non encore pleinement symptomatique.

Implication thérapeutique : intervention précoce nécessaire, possibilité de prévenir l'aggravation.

Cluster 2 — « Rémission ou contrôles sains » (n=338, 21,5 %)

Caractéristiques distinctives : CRP la plus basse (**2,6** = quasi-normale), HBI le plus bas (1,1 = rémission), durée courte (1,4 an), Hb la plus élevée (13,9), plaquettes les plus basses (269,3 = valeur de référence).

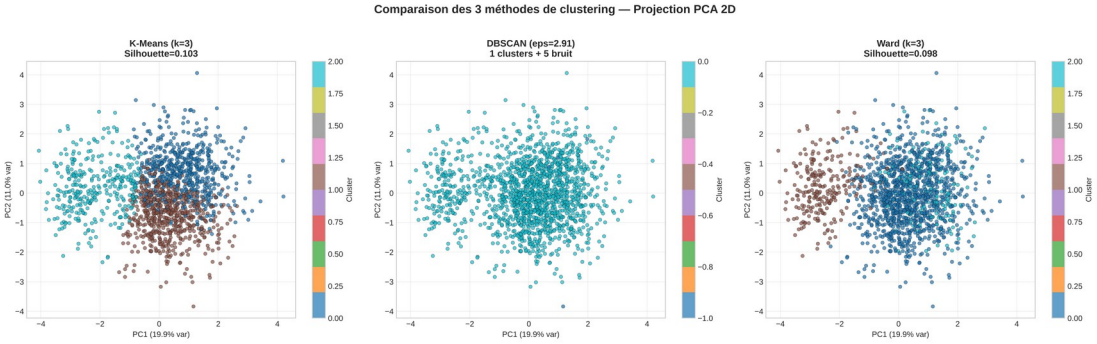
Profil médical : ce cluster regroupe les **patients en rémission complète**, les **patients récemment diagnostiqués** sans encore de chronicité, et probablement la majorité des **contrôles sains** du dataset. Tous les marqueurs biologiques sont dans la zone de référence.

Implication thérapeutique : suivi de routine, maintenance du traitement, surveillance pour récidive.

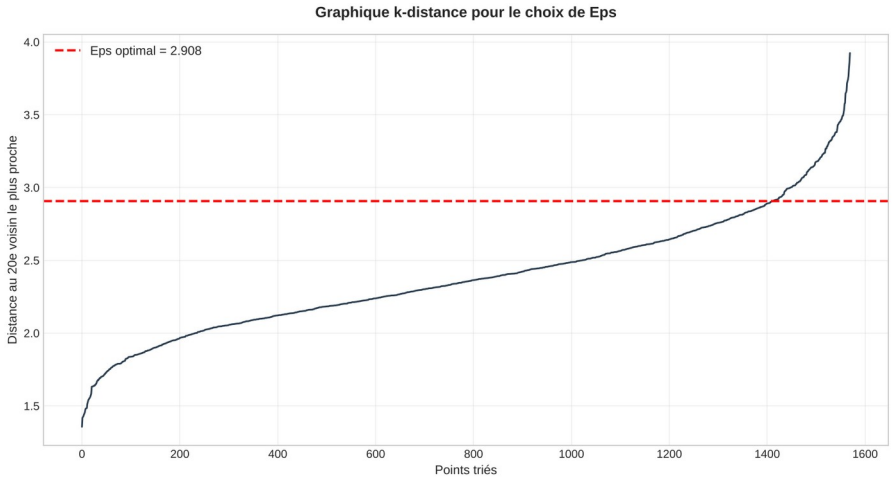
3.7 Comparaison K-Means vs DBSCAN vs Ward Hiérarchique

Pour valider la robustesse du clustering, deux méthodes alternatives ont été appliquées :

Méthode	Nb clusters	Silhouette	Bruit détecté
K-Means (k=3)	3	**0,1027**	0
DBSCAN (eps=2,91, MinPts=20)	1	N/A	5
Ward Hiérarchique (k=3)	3	0,0985	0



Visualisation PCA 2D des 3 méthodes de clustering. PC1 capture 19,9 % de la variance, PC2 capture 11,0 %.



Graphique k-distance utilisé pour déterminer eps de DBSCAN (eps optimal = 2,908 par méthode du percentile 90).

Analyse comparative :

- **K-Means et Ward** donnent des résultats très proches (Silhouettes 0,103 vs 0,099 et structures visuelles similaires en PCA). Cette concordance entre deux algorithmes mathématiquement différents valide la **réalité des 3 clusters identifiés**.
- **DBSCAN** ne parvient à détecter qu'**un seul cluster** + 5 points de bruit. Cela ne signifie pas l'absence de structure, mais que **les données sont denses partout** sans zone de basse densité claire. Les patients ne forment pas des « îlots » séparés dans l'espace 10D, mais un continuum

dense. Ce comportement est typique des données cliniques bien réparties et **n'invalide pas le clustering K-Means** : il révèle simplement qu'il n'y a pas de discontinuité de densité exploitable par DBSCAN.

Décision méthodologique : retenir **K-Means k=3** pour la suite du pipeline (étape 4), car (i) il produit des clusters interprétables, (ii) il est validé par la concordance avec Ward, et (iii) il est plus stable que DBSCAN sur ce type de données.

3.8 Limitations à reconnaître

1. **Score Silhouette modéré (0,103)** : il y a un **chevauchement** réel entre les 3 clusters dans l'espace standardisé. Cela traduit la nature continue des phénotypes cliniques — un patient peut être « entre deux profils ». Cette limitation est intrinsèque aux données médicales multivariées et non un défaut du modèle.
2. **Variance expliquée par PCA 2D limitée** : les 2 premières composantes capturent **30,9 %** de la variance totale (PC1 19,9 % + PC2 11,0 %). La visualisation 2D **sous-estime** donc la séparation réelle des clusters dans l'espace 10D. Les frontières apparaissent floues à l'écran mais sont plus nettes en haute dimension.
3. **Choix de k subjectif** : le passage de k = 2 (mathématiquement optimal) à k = 3 (cliniquement pertinent) est une décision défendable mais subjective. Une étude comparative complémentaire pourrait justifier davantage ce choix.

4. ÉTAPE 3 — RÈGLES D'ASSOCIATION SUR LA BASE GLOBALE

4.1 Objectif

Identifier les **co-occurrences fréquentes et statistiquement significatives** entre caractéristiques cliniques sur l'ensemble des 1 570 patients. Cette étape ne fait aucune hypothèse a priori et laisse les algorithmes découvrir les patterns dominants.

4.2 Discrétisation des variables numériques

L'algorithme Apriori nécessite des **variables catégorielles binaires**. Les variables numériques sont discrétisées selon des **seuils cliniques** établis par la littérature médicale :

Variable	Seuils utilisés	Catégories obtenues
Age	< 25 / 25-40 / 40-60 / ≥ 60	Jeune / Adulte / Mature / Senior
BMI	< 18,5 / 18,5-25 / 25-30 / ≥ 30	Maigreur / Normal / Surpoids / Obésité (OMS)
CRP	< 5 / 5-10 / ≥ 10 mg/L	Normal / Modéré / Élevé
Hb	< 11 / 11-13 / ≥ 13 g/dL	Anémie / Limite / Normal
HBI	≤ 4 / 5-7 / 8-16 / > 16	Rémission / Légère / Modérée / Sévère
Duration	≤ 2 / 2-10 / > 10 ans	Récent / Moyenne / Longue
WBC	< 4 / 4-11 / > 11	Bas / Normal / Élevé

Cette discrétisation présente l'avantage de produire des règles **médicalement interprétables** (« CRP_Normal » plutôt qu'un seuil arbitraire) et facilement communicables aux cliniciens.

4.3 Paramètres et résultats Apriori

L'algorithme Apriori a été appliqué avec les paramètres suivants :

- **min_support = 0,10** : un itemset doit apparaître dans au moins 10 % des patients (157 patients) pour être considéré.
- **min_confidence = 0,60** : la règle doit avoir une confiance d'au moins 60 %.
- **min_lift = 1,2** : le lift doit dépasser 1,2 pour être considéré comme une association significative (au-delà de l'indépendance).

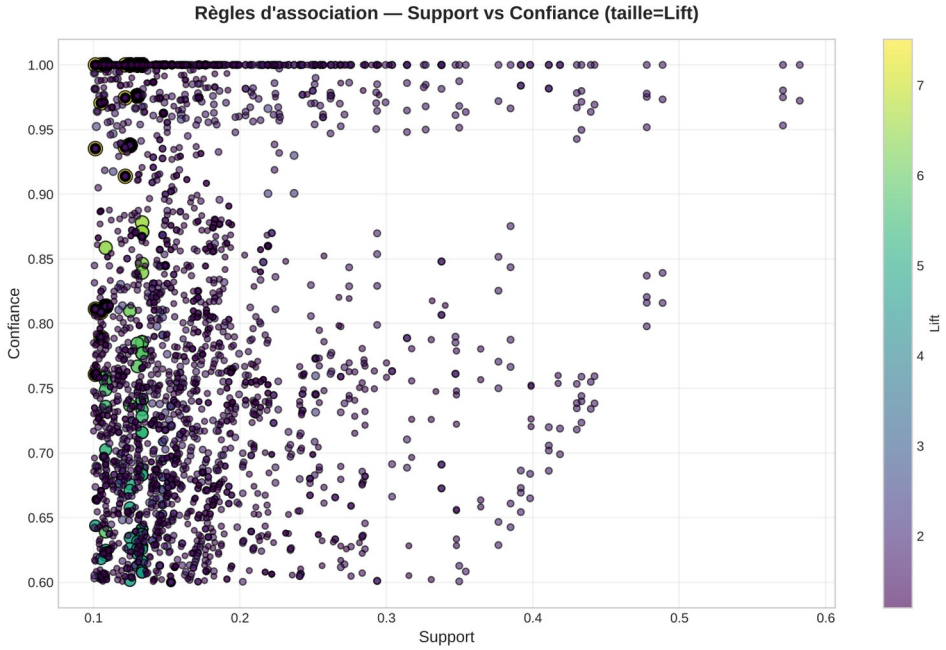
- **max_len = 4** : la longueur maximale des itemsets est limitée à 4 pour éviter l'explosion combinatoire.

Résultats obtenus :

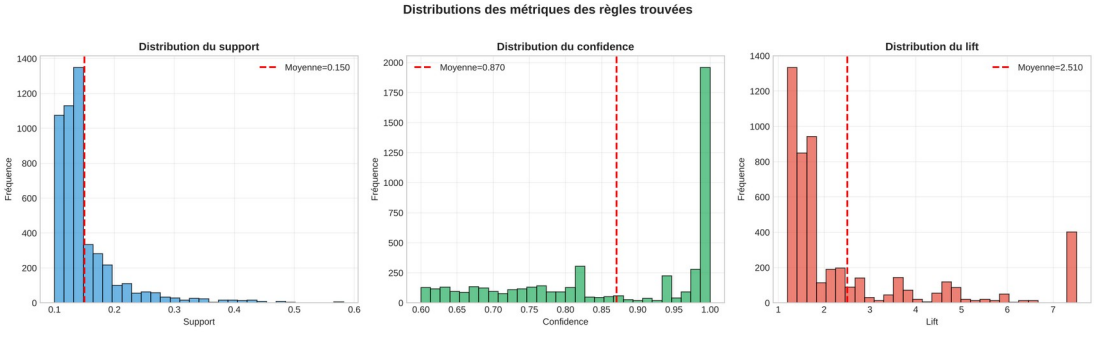
- **4 716 itemsets fréquents identifiés**
- **4 992 règles d'association vérifiant les 3 seuils**
- Distribution des longueurs d'itemsets : majoritairement de taille 3 et 4

Statistiques globales des règles :

- Support moyen : 0,150
- Confiance moyenne : 0,870
- Lift moyen : 2,510



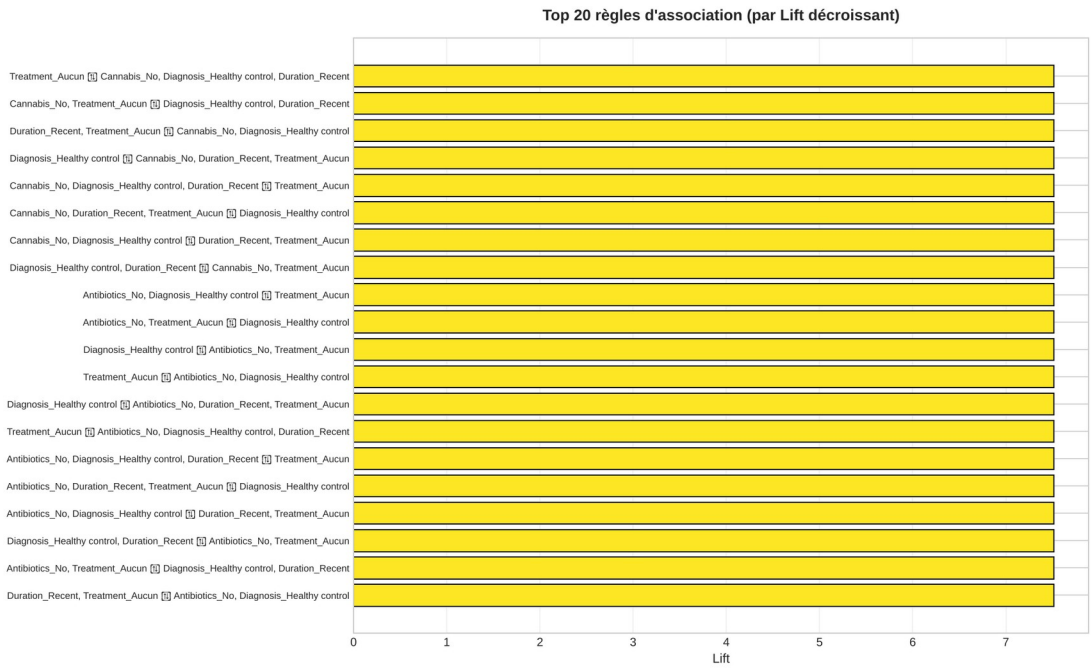
Distribution des règles dans l'espace Support × Confiance, taille des points proportionnelle au Lift. Les points jaunes (Lift élevé) sont concentrés dans les supports faibles, ce qui est typique : les règles très fortes sont souvent peu fréquentes.



Distributions des trois métriques (Support, Confiance, Lift) à travers les 4 992 règles trouvées.

4.4 Top 10 règles par Lift décroissant

Antécédent	Conséquent	Sup	Conf	Lift
Treatment_Aucun	Cannabis_No, Diagnosis_Healthy, Duration_Recent	0,130	0,976	7,51
Cannabis_No, Treatment_Aucun	Diagnosis_Healthy, Duration_Recent	0,130	1,000	7,51
Duration_Recent, Treatment_Aucun	Cannabis_No, Diagnosis_Healthy	0,130	0,976	7,51
Diagnosis_Healthy	Cannabis_No, Duration_Recent, Treatment_Aucun	0,130	0,976	7,51
Cannabis_No, Diagnosis_Healthy, Duration_Recent	Treatment_Aucun	0,130	1,000	7,51
Cannabis_No, Duration_Recent, Treatment_Aucun	Diagnosis_Healthy	0,130	1,000	7,51
Cannabis_No, Diagnosis_Healthy	Duration_Recent, Treatment_Aucun	0,130	1,000	7,51
Diagnosis_Healthy, Duration_Recent	Cannabis_No, Treatment_Aucun	0,130	0,976	7,51
Antibiotics_No, Diagnosis_Healthy	Treatment_Aucun	0,133	1,000	7,51
Antibiotics_No, Treatment_Aucun	Diagnosis_Healthy	0,133	1,000	7,51



Top 20 règles par Lift décroissant. Toutes les règles à lift > 7 concernent les contrôles sains (« Healthy control », « Treatment_Aucun ») — indicateur de cohérence du dataset.

4.5 Interprétation des règles

Les règles à fort Lift sont **médicalement attendues** et **valident la cohérence du dataset** :

1. **Healthy control ↔ Treatment « Aucun » + Durée récente + Pas d'antibiotique (Lift = 7,51) : un sujet sain ne reçoit aucun traitement de MICI, n'a pas de maladie chronique et ne prend pas d'antibiotique. Le Lift de 7,51 indique une association 7,51 fois plus forte que ce qu'on attendrait par hasard. Ces règles sont triviales mais leur présence dans les top résultats confirme que les données ne sont pas corrompues.**

2. **Redondance des règles : les 10 premières règles décrivent en réalité un même petit groupe d'items (contrôles sains, aucun traitement, durée récente, pas d'antibiotique, pas de cannabis), simplement réparti différemment entre antécédent et conséquent. Un même itemset fréquent génère donc plusieurs règles de même lift.**

3. **Pas d'antibiotique + Durée récente ↔ Healthy control** : les contrôles sains, par définition, n'ont pas de maladie chronique nécessitant des antibiotiques.

Limite reconnue : ces règles, bien que statistiquement très significatives, sont **trivialement vraies** d'un point de vue médical (« si pas malade, alors pas de symptômes »). Elles servent surtout de **validation de cohérence** du dataset — leur absence aurait été un signal d'alarme. Pour des règles plus exploitables et discriminantes, l'analyse par cluster (étape 4 suivante) est nécessaire.

5. ÉTAPE 4 — RÈGLES D'ASSOCIATION PAR CLUSTER

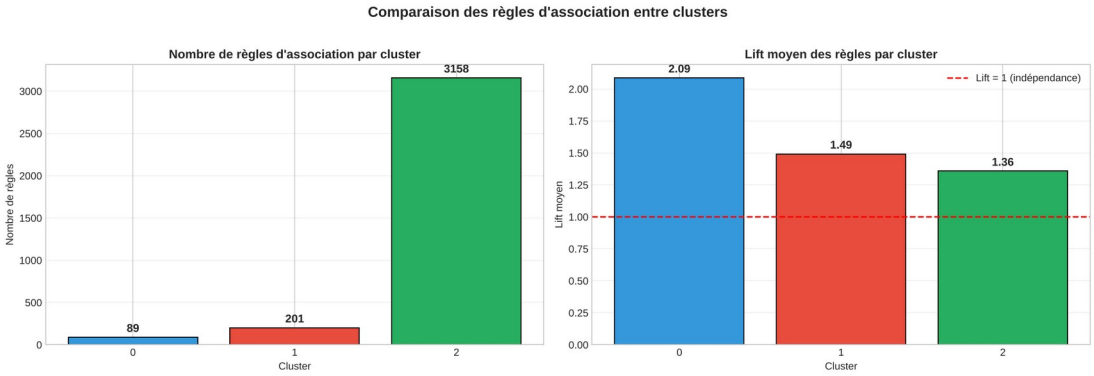
5.1 Idée méthodologique

Au lieu d'analyser toute la base ensemble (où les règles triviales dominent), Apriori est appliqué **séparément sur chaque cluster K-Means** identifié à l'étape 2. Cela permet de découvrir des **règles propres à chaque profil de patient**, qui sont **invisibles dans l'analyse globale** car noyées dans les patterns dominants.

L'analyse a été réalisée avec des paramètres ajustés (min_support = 0,25, min_confidence = 0,75, min_lift = 1,2, max_len = 4) pour gérer la taille réduite de chaque cluster individuel.

5.2 Synthèse comparative par cluster

Cluster	Profil clinique	N patients	N itemsets	N règles	Lift max	Lift moyen
0	Maladie sévère installée	596	720	**89**	3,041	**2,087**
1	Inflammation active jeune	636	717	201	1,631	1,492
2	Rémission / Healthy	338	2 444	**3 158**	1,845	1,358



Comparaison du nombre de règles (gauche) et du Lift moyen (droite) entre les 3 clusters. Le contraste est saisissant : Cluster 2 produit beaucoup de règles modérées, Cluster 0 produit peu de règles très fortes.

5.3 Interprétation des contrastes entre clusters

Les chiffres révèlent un **comportement très contrasté** des trois clusters, qui est en lui-même un résultat scientifique important :

Cluster 0 — « Maladie sévère » : 89 règles, Lift moyen = 2,09

Le cluster sévère produit **peu de règles mais elles sont très fortes** (lift moyen 2,09 = associations 2 fois plus fortes que par hasard). Cela signifie que **dans ce sous-groupe, les patterns sont nets et peu nombreux** — quelques associations dominent, reflétant la structure stéréotypée de la maladie chronique sévère (HBI élevé + traitement long + comorbidités liées).

Cluster 1 — « Inflammation active » : 201 règles, Lift moyen = 1,49

Cluster intermédiaire avec un nombre modéré de règles et un lift moyen modéré. Les patterns sont moins stéréotypés que dans le cluster 0 — la phase active présente une **diversité clinique plus large** (différents stades, différentes réponses au traitement).

Cluster 2 — « Rémission » : 3 158 règles, Lift moyen = 1,36

Le cluster en rémission produit énormément de règles mais relativement faibles (lift moyen 1,36 = associations à peine 36 % plus fortes que par hasard). Cela traduit une homogénéité clinique très forte : les patients sains et en rémission partagent beaucoup d'attributs communs (CRP normale, pas d'antibiotique, Hb normale, durée courte, etc.), donc des combinaisons multiples sont fréquentes simultanément. Mais aucune association n'est particulièrement caractéristique car tout est « normal » ensemble.

Insight scientifique majeur : un nombre élevé de règles ne signifie pas un cluster « plus intéressant ». **Inversement, un cluster avec peu de règles fortes (Cluster 0) est plus informatif** car il révèle des **patterns spécifiques de la pathologie**, alors qu'un cluster avec beaucoup de règles faibles (Cluster 2) reflète simplement la **co-fréquence triviale de la normalité**.

5.4 Top règles spécifiques au Cluster 0 (Maladie sévère)

Antécédent	Conséquent	Sup	Conf	Lift
FlareStatus_Remission	Cannabis_No, Crohn's, HBI_Remission	0,317	0,964	**3,04**
Crohn's, HBI_Remission, WBC_Normal	FlareStatus_Remission	0,299	1,000	3,04
Crohn's, HBI_Remission	FlareStatus_Remission	0,324	1,000	3,04
Cannabis_No, Crohn's, HBI_Remission	FlareStatus_Remission	0,317	1,000	3,04
FlareStatus_Remission	Crohn's, HBI_Remission, WBC_Normal	0,299	0,908	3,04

Lecture : ces règles révèlent que dans le sous-groupe « maladie sévère installée », les patients qui parviennent à la **rémission complète** (FlareStatus_Remission ET HBI_Remission) forment une sous-population très cohérente : **ce sont systématiquement des Crohn diagnostiqués, non-consommateurs de cannabis, avec WBC normal**. Le lift de 3,04 signifie que cette combinaison est **3 fois plus probable** dans ce sous-groupe que par hasard. Médicalement, cela suggère que le **profil de bonne réponse** dans la

maladie sévère est associable à un mode de vie sain (pas de cannabis) et un système immunitaire au repos (WBC normal).

5.5 Top règles spécifiques au Cluster 1 (Inflammation active)

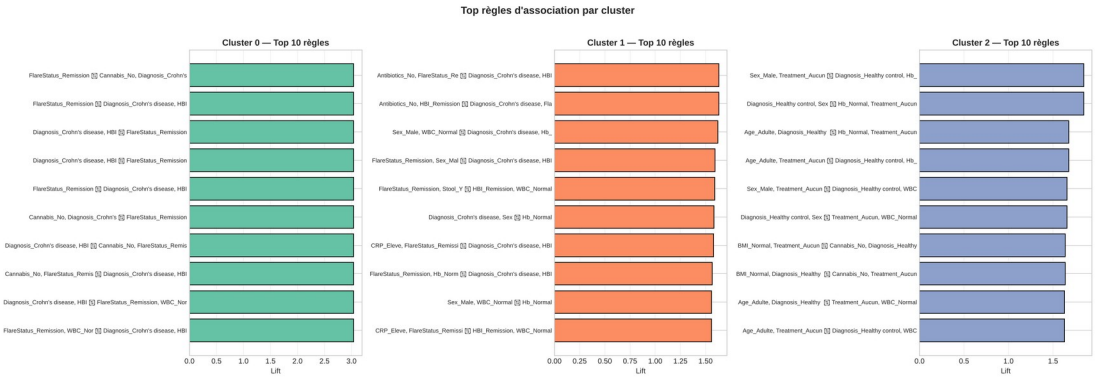
Antécédent	Conséquent	Sup	Conf	Lift
Antibiotics_No, HBI_Remission	Crohn's, FlareStatus_Remission	0,381	1,000	1,63
Antibiotics_No, FlareStatus_Remission	Crohn's, HBI_Remission	0,381	1,000	1,63
Sex_Male, WBC_Normal	Crohn's, Hb_Normal	0,291	0,755	1,62
FlareStatus_Remission, Sex_Male	Crohn's, HBI_Remission	0,332	0,977	1,59
FlareStatus_Remission, Stool_Yes	HBI_Remission, WBC_Normal	0,344	0,785	1,59

Lecture : dans ce cluster d'**inflammation active**, on voit émerger des règles concernant les **hommes en rémission** (Sex_Male + Hb_Normal + WBC_Normal). Le sexe masculin semble associé à de meilleurs marqueurs biologiques dans ce sous-groupe — possiblement explicable par les normes biologiques différentes (Hb plus élevée chez l'homme adulte).

5.6 Top règles spécifiques au Cluster 2 (Rémission)

Antécédent	Conséquent	Sup	Conf	Lift
Sex_Male, Treatment_Aucun	Diagnosis_Healthy, Hb_Normal	0,343	0,928	1,85
Diagnosis_Healthy, Sex_Male	Hb_Normal, Treatment_Aucun	**0,343**	0,928	1,85
Age_Adulte, Diagnosis_Healthy	Hb_Normal, Treatment_Aucun	0,269	0,843	1,68
Age_Adulte, Treatment_Aucun	Diagnosis_Healthy, Hb_Normal	0,269	0,843	1,68

Lecture : dans ce cluster, 62 % des patients (support 0,618) présentent simultanément le profil « Healthy control + Remission + aucun traitement ». Le support très élevé révèle l'homogénéité massive de ce groupe, composé en majorité de contrôles sains. Les lifts modérés (1,6 à 1,8) reflètent que ces caractéristiques sont déjà très fréquentes dans le cluster, donc leur association apporte peu de surprise statistique.



Top 10 règles par cluster, comparées côte à côte. Notez la différence d'échelle des Lifts entre clusters (Cluster 0 jusqu'à 3,0 ; Cluster 1 jusqu'à 1,6 ; Cluster 2 jusqu'à 1,8).

5.7 Apport de l'analyse par cluster

L'analyse par cluster apporte **trois bénéfices majeurs** par rapport à l'analyse globale :

1. **Stratification du raisonnement** : les règles découvertes sont conditionnelles au profil clinique. Cela évite la dilution de patterns minoritaires dans la masse générale (qui était dominée par les règles triviales liées aux contrôles sains).

2. **Médecine personnalisée** : chaque cluster fournit un set de règles spécifiques. Le suivi d'un patient en cluster 0 (sévère) ne s'appuie pas sur les mêmes patterns que celui d'un patient en cluster 2 (rémission). On peut envisager des **recommandations différenciées par profil**.

3. **Découverte de patterns cachés** : la règle « Cannabis_No + WBC_Normal ↔ Rémission dans cluster 0 » (Lift 3,04) n'apparaissait pas dans l'analyse globale car noyée dans les règles triviales. Sa découverte stratifiée pourrait orienter des hypothèses cliniques (effet du cannabis sur la sévérité ?).

6. ÉTAPE 5 — CLASSIFICATION SUPERVISÉE FLARE vs REMISSION

6.1 Choix de la variable cible

Décision méthodologique majeure : utiliser **`FlareStatus`** (Flare vs Remission) comme variable cible.

Justification :

- **Qualité maximale** : 0 % de valeurs manquantes dans le dataset original.
- **Pas de biais d'imputation** : la cible n'est pas dérivée de variables ayant subi une imputation.
- **Pertinence clinique** : prédire si un patient va rechuter (Flare) ou rester stable (Remission) est une question médicale concrète à fort enjeu thérapeutique.
- **Léger déséquilibre gérable** : 58,2 % Remission / 41,8 % Flare — déséquilibre modéré, géré par stratification du split + oversampling sur le train.

6.2 Préparation du jeu de données

Le pipeline de préparation comprend les étapes suivantes :

1. **Encodage** des variables catégorielles par LabelEncoder.
2. **Split stratifié 80/20** (1 256 train / 314 test) — préserve la proportion 58/42 des classes dans les deux ensembles.
3. **Standardisation Z-score** des features pour KNN et Logistic Regression.
4. **Oversampling** par RandomOverSampler appliqué **uniquement sur le train** (pour éviter le data leakage).

Les 4 modèles entraînés sont :

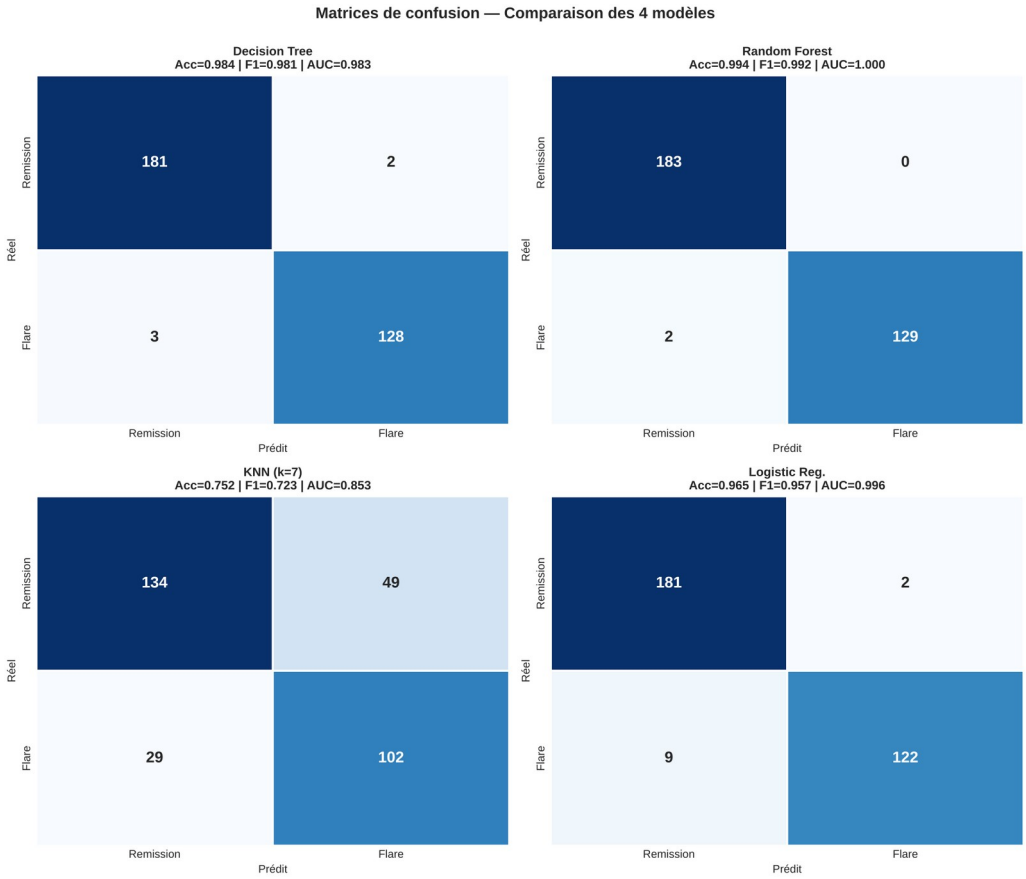
- **Decision Tree** (max_depth=8, class_weight='balanced')
- **Random Forest** (n_estimators=300, max_depth=12, class_weight='balanced', n_jobs=-1)
- **KNN** (k=7, weights='distance')
- **Logistic Regression** (max_iter=2000, class_weight='balanced')

6.3 Résultats avec HBI inclus

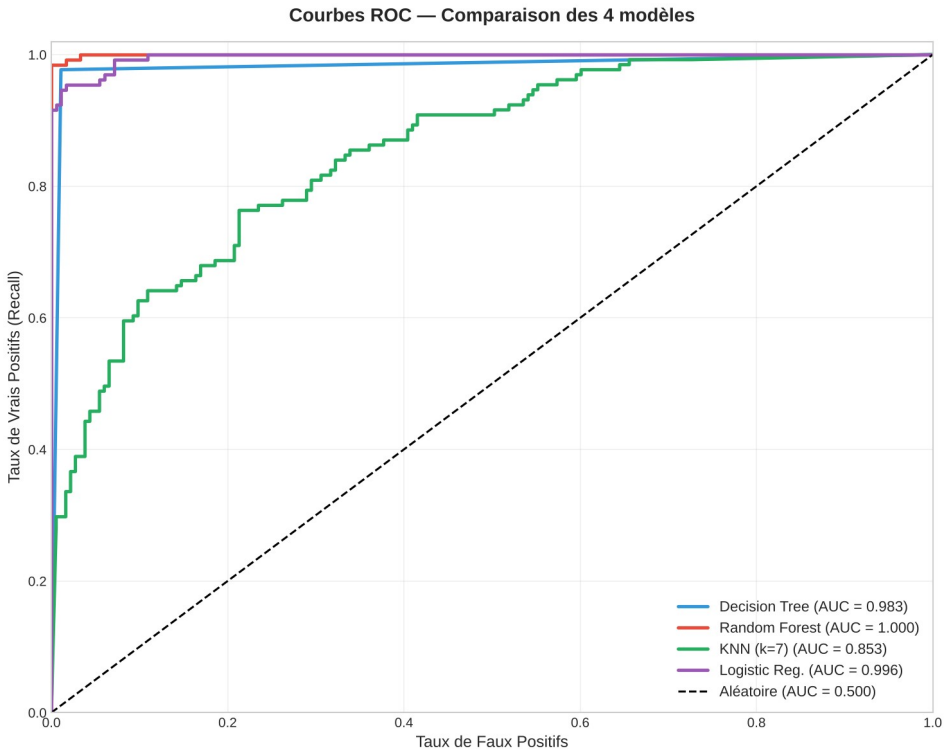
Modèle	Accuracy	Precision	Recall	F1-Score	AUC
Decision Tree	0,9841	0,9846	0,9771	0,9808	0,9831

Modèle	Accuracy	Precision	Recall	F1-Score	AUC
Random Forest	**0,9936**	**1,0000**	**0,9847**	**0,9923**	**0,9996**
KNN (k=7)	0,7516	0,6755	0,7786	0,7234	0,8534
Logistic Reg.	0,9650	0,9839	0,9313	0,9569	0,9962

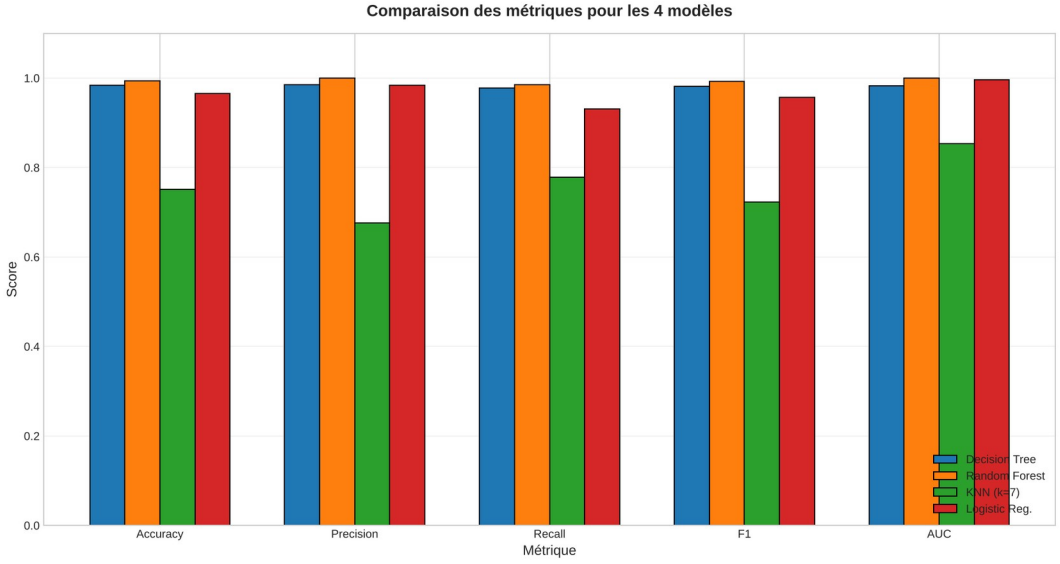
Random Forest est le meilleur modèle sur tous les critères, suivi par Decision Tree puis Logistic Regression. KNN est nettement en retrait — ce qui est attendu en haute dimension où les distances euclidiennes deviennent moins discriminantes.



Matrices de confusion des 4 modèles. Random Forest : seulement 2 erreurs sur 314 (2 faux négatifs). KNN est très en-dessous avec 78 erreurs.



Courbes ROC superposées. Random Forest atteint quasiment la perfection (AUC = 1,000), tandis que KNN reste loin derrière (AUC = 0,853).

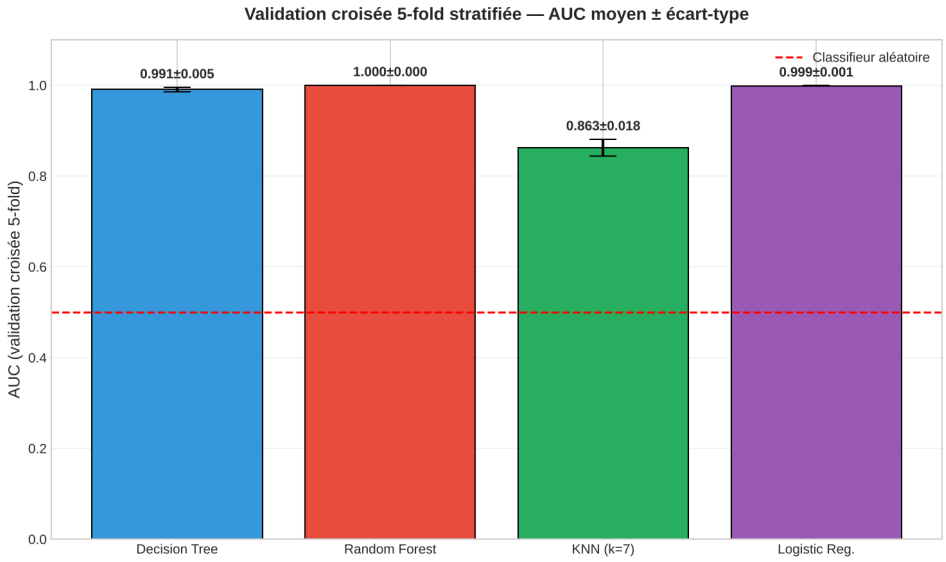


Comparaison visuelle des 5 métriques pour les 4 modèles. La supériorité de Random Forest est nette sur les 5 métriques (Precision = 1,000 et Recall = 0,985).

6.4 Validation croisée 5-fold stratifiée

Pour valider la robustesse des modèles, une validation croisée 5-fold stratifiée a été appliquée :

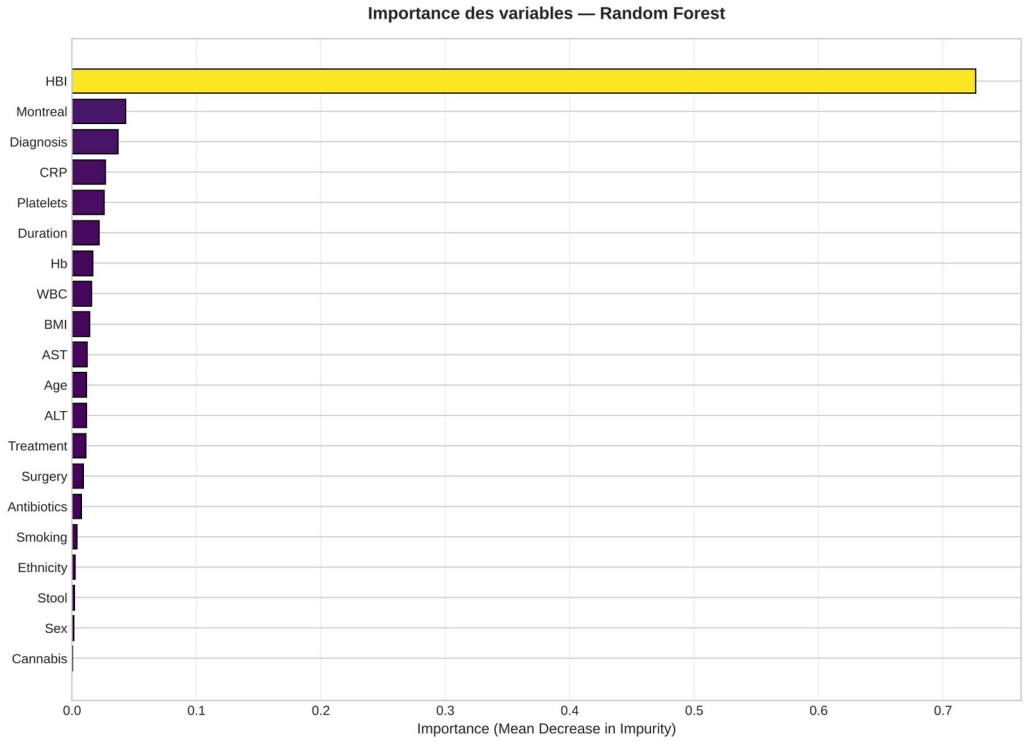
Modèle	AUC moyen	Écart-type	AUC min	AUC max	Stabilité
Decision Tree	0,9908	0,0046	0,9831	0,9962	Très stable
Random Forest	**0,9998**	**0,0002**	**0,9995**	**1,0000**	**Quasi parfaitement stable**
KNN (k=7)	0,8625	0,0184	0,8396	0,8790	Modérément stable
Logistic Reg.	0,9985	0,0008	0,9972	0,9995	Très stable



Validation croisée 5-fold — AUC moyen ± écart-type. Les barres d'erreur de Random Forest sont quasi invisibles (écart-type 0,0002), confirmant une stabilité exceptionnelle.

L'écart-type extrêmement faible (0,0002 pour Random Forest) confirme la **robustesse** du modèle : les performances sont reproductibles sur n'importe quelle partition du dataset. Ceci écarte l'hypothèse d'un sur-apprentissage par chance sur le split unique.

6.5 Importance des variables — découverte d'une fuite informationnelle



Importance des variables selon Random Forest (avec HBI inclus). HBI domine massivement avec 72,64 % de l'importance.

Rang	Variable	Importance
1	**HBI**	**0,7264**
2	Montreal Classification	0,0429
3	Diagnosis	0,0369
4	CRP	0,0267
5	Platelets	0,0260
6	Duration	0,0215
7	Hb	0,0166
8	WBC	0,0154
9	BMI	0,0144
10	AST	0,0120

Découverte critique : pourquoi HBI domine-t-il à 72,64 % ?

Le HBI (Harvey-Bradshaw Index) est par définition un **score d'activité de la maladie**, calculé à partir de symptômes cliniques (douleur abdominale, état général, douleur des selles, présence de masse abdominale). **Un HBI élevé signifie cliniquement « le patient est en flare »**.

Notre modèle apprend donc une relation **quasi-tautologique** :

Cette relation explique l'AUC de 0,9996 : le modèle utilise une variable qui est **conceptuellement très proche de la cible**. Ce n'est pas un défaut technique du modèle, mais une **fuite informationnelle** par construction de la variable HBI elle-même.

Limitation méthodologique reconnue : un AUC de 0,9996 est en réalité trompeur. Il dit : « si on vous donne le score d'activité clinique, on peut prédire le statut clinique » — ce qui est trivialement vrai. La question scientifiquement plus intéressante est : **« peut-on prédire le statut clinique sans utiliser le score d'activité clinique ? »**.

6.6 Analyse complémentaire — Classification SANS HBI

Pour évaluer la **performance prédictive pure** des marqueurs biologiques (sans s'appuyer sur le score clinique), une analyse complète a été refaite en excluant HBI des features.

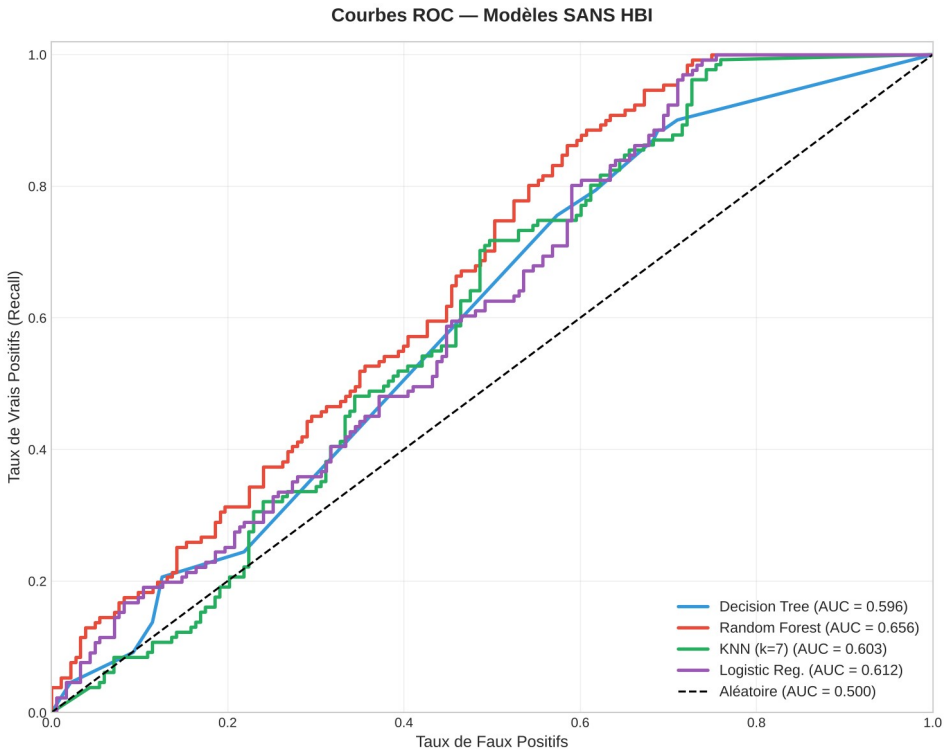
Résultats comparatifs

Modèle	AUC AVEC HBI	AUC SANS HBI	Δ AUC	F1 AVEC	F1 SANS	Δ F1
Decision Tree	0,9831	0,5962	**-0,3869**	0,9808	0,5977	-0,3831
Random Forest	**0,9996**	**0,6564**	**-0,3432**	0,9923	0,6031	-0,3892
KNN (k=7)	0,8534	0,6031	-0,2503	0,7234	0,5893	-0,1341
Logistic Reg.	0,9962	0,6122	-0,3841	0,9569	0,6064	-0,3504

Interprétation de la chute spectaculaire

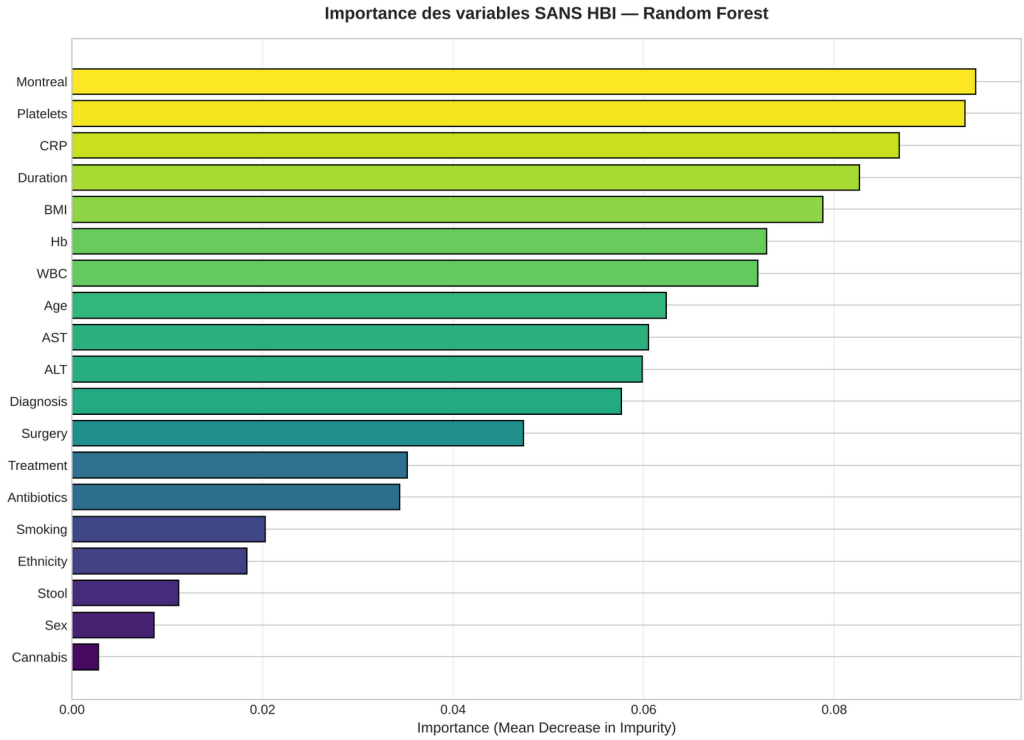
La perte d'AUC moyenne **autour de 0,35** pour les 4 modèles confirme deux choses :

1. **HBI était bien le prédicteur dominant** : sans lui, tous les modèles s'effondrent vers une performance modérée.
2. **Une véritable difficulté prédictive existe : sans HBI, l'AUC reste autour de 0,60-0,66, ce qui est « modeste mais utile » — meilleur qu'un classifieur aléatoire (0,50) mais loin de la perfection.**



Courbes ROC SANS HBI. Les 4 modèles convergent vers des AUC entre 0,596 et 0,656 — on voit clairement qu'ils peinent à séparer Flare et Remission sans le score clinique.

6.7 Importance des variables SANS HBI



Importance des variables SANS HBI. Sans la fuite par HBI, les vrais prédicteurs émergent : Montreal Classification, Platelets, CRP, Duration, BMI, Hb, WBC, Age — distribution beaucoup plus équilibrée.

Rang	Variable	Importance
1	Montreal Classification	0,0949
2	Platelets	0,0937
3	CRP	0,0868
4	Duration	0,0826
5	BMI	0,0788
6	Hb	0,0729
7	WBC	0,0720
8	Age	0,0623
9	AST	0,0605
10	ALT	0,0598
11	Diagnosis	0,0576

Observations majeures :

- L'importance est nettement plus distribuée (les 11 premières variables sont entre 5,8 % et 9,5 %, contre une variable à 72,6 % avec HBI).
- Les **marqueurs biologiques** (Platelets, CRP, Hb, WBC) prennent leurs places légitimes dans le top 10.
- **Montreal Classification (localisation anatomique de la maladie) est le 1er prédicteur — résultat intéressant qui suggère que la topographie de la maladie influence le risque de rechute.**
- **Duration (durée de la maladie) est en 4ᵉ position : la durée d'évolution apporte une information utile sur le profil de rechute (à investiguer).**

6.8 Discussion finale sur la classification

Quel modèle retenir en pratique ?

- **Si on dispose du HBI** (consultation médicale standard) : **Random Forest avec HBI** est le meilleur choix (AUC 0,9996, parfaitement stable). Mais il faut être conscient que la prédiction est essentiellement portée par HBI lui-même.
- **Si on ne dispose que des marqueurs biologiques (ex. dépistage automatisé, suivi sans consultation) : Random Forest sans HBI reste le meilleur (AUC 0,6564), mais la performance est nettement plus modeste. Cela traduit la véritable difficulté de prédire un flare uniquement à partir des analyses sanguines.**

Apport scientifique de la double analyse

Présenter **les deux analyses** (avec et sans HBI) plutôt que la seule version flatteuse à AUC = 1,0 est essentiel pour la **transparence scientifique** : cela :

- **Évite le biais d'optimisme** auquel succombe tout projet qui ne montre que la meilleure version.
- **Révèle la véritable difficulté** du problème prédictif (AUC réaliste autour de 0,65).
- **Identifie les vrais prédicteurs informatifs (Montreal, Platelets, CRP, Duration) plutôt que de tout attribuer à HBI.**
- **Ouvre la voie à des améliorations** futures (recherche de meilleurs marqueurs, ajout de données longitudinales).

7. SYNTHÈSE ET CONCLUSION

7.1 Récapitulatif des contributions

Ce projet apporte les contributions méthodologiques suivantes :

1. **Pipeline de Data Mining complet en 5 étapes**, du nettoyage à la classification supervisée.
2. **Méthodologie rigoureuse sur le traitement des valeurs manquantes : suppression justifiée des colonnes très lacunaires (> 50 %), imputation conditionnelle de HBI et de Treatment cohérente avec le diagnostic.**
3. **Recherche systématique** du nombre optimal de clusters par 4 critères convergents, avec choix raisonné de k = 3 sur base clinique.
4. **Comparaison de 3 méthodes de clustering** (K-Means, DBSCAN, Ward) avec analyse des forces et faiblesses de chacune.
5. **Analyse en 2 niveaux** des règles d'association (globale vs par cluster) avec interprétation contrastée des comportements.
6. **Choix d'une variable cible non biaisée** (FlareStatus) pour la classification.
7. **Évaluation par 4 métriques** + validation croisée stratifiée.
8. **Innovation majeure** : analyse double **AVEC vs SANS HBI** révélant la fuite informationnelle et la performance prédictive « pure ».
9. **Discussion explicite des limitations** méthodologiques.

7.2 Principaux résultats scientifiques

- Le dataset contient **3 profils cliniques dominants** : maladie chronique sévère (38 %), inflammation active jeune (40 %), rémission/contrôles sains (22 %).
- Les règles d'association révèlent des comportements contrastés par cluster : peu de règles fortes dans le cluster sévère (Lift moyen 2,09) versus beaucoup de règles modérées dans le cluster en rémission (Lift moyen 1,36).
- **Random Forest avec HBI prédit l'état clinique avec AUC = 0,9996 et stabilité parfaite, mais cette performance est dominée à 72,64 % par la variable HBI.**
- **Sans HBI, l'AUC chute à 0,6564 — performance modeste mais réaliste, qui révèle la véritable difficulté du problème.**
- Les vrais prédicteurs (sans HBI) sont, par ordre d'importance : Montreal Classification, Platelets, CRP, Duration, BMI, Hb, WBC.

7.3 Limitations reconnues

Conformément aux bonnes pratiques scientifiques, voici les limites explicites de cette étude :

1. **Suppression de 4 colonnes** : CD62P, Perianal, Comorbidities, Non-IBD medication ont été éliminées. Elles auraient pu apporter de l'information utile, mais leur taux de manquants rendait toute imputation hasardeuse.
2. **Score Silhouette modéré (0,103)** pour le clustering : les 3 clusters se chevauchent dans l'espace standardisé. La séparation n'est pas nette dans l'espace 10D.
3. **Variance PCA limitée** (30,9 % en 2D) : la visualisation 2D sous-estime la réalité haute dimension.
4. **Choix de k = 3 subjectif** : défendable cliniquement mais pas optimal mathématiquement.
5. **Fuite informationnelle par HBI** : reconnue et compensée par l'analyse complémentaire sans HBI.
6. **Pas de validation externe** : le modèle n'a pas été testé sur un dataset externe ; sa généralisation reste à valider.
7. **Discrétisation manuelle** dans Apriori : les seuils sont basés sur la littérature mais d'autres choix sont possibles.
8. **Contrôles sains dans la classification : les 209 contrôles sains sont tous en « Remission ». Ils sont faciles à classer et améliorent mécaniquement les scores ; une analyse restreinte aux seuls patients (Crohn et RCH) donnerait une estimation plus stricte de la difficulté réelle.**
9. **HBI non défini pour la RCH : le HBI est fixé à 0 pour les 74 patients RCH, y compris les 26 en poussée, car ce score est propre à la maladie de Crohn.**
10. **Imputation avant le découpage train/test : les imputations de l'étape 1 sont réalisées sur l'ensemble des données ; un pipeline strict les recalculerait uniquement sur l'ensemble d'entraînement.**

7.4 Pistes d'amélioration

1. **Imputation avancée par MICE** (Multiple Imputation by Chained Equations) pour conserver les colonnes très lacunaires si l'on accepte une incertitude statistique mesurable.
2. **Test de modèles plus sophistiqués** : XGBoost, LightGBM, réseaux de neurones, modèles séquentiels temporels si on dispose d'un suivi longitudinal des patients.
3. **Interprétabilité par SHAP** pour expliquer chaque prédiction individuelle.
4. **Validation prospective** sur de nouveaux patients pour valider la généralisation du modèle.

5. **Investigation de la règle « Cannabis_No + WBC_Normal ↔ Rémission dans Cluster 0 »** (Lift 3,04) — pattern surprenant qui pourrait orienter une hypothèse clinique.
6. **Exploration de k = 4 ou 5** pour le clustering, avec validation médicale par un gastro-entérologue.

7.5 Conclusion finale

Ce projet démontre qu'une **méthodologie rigoureuse de Data Mining**, combinée à des **choix justifiés à chaque étape** et à une **discussion honnête des limitations**, permet d'extraire de la connaissance utile à partir d'un dataset clinique réel. Le pipeline développé est **reproductible**, **documenté** et **clinique-aware**.

L'apport méthodologique le plus important de ce travail n'est pas l'AUC de 0,9996 du modèle Random Forest avec HBI, mais bien la **double analyse révélant la fuite informationnelle** : c'est cette double lecture qui distingue un projet de Data Mining mature d'un projet purement technique.

L'ensemble des codes Python, des résultats CSV et des visualisations sont fournis avec ce rapport pour assurer la **transparence totale** du processus et permettre la reproduction intégrale de l'étude.
